Computación Alto Rendimiento - Práctica 1

Evaluación del rendimiento

Jose Francisco Hurtado Valero[1] y Carlos Salas Alarcón[1]

[1] Universidad Alicante, Carr. de San Vicente del Raspeig, s/n, 03690 San Vicente del Raspeig, Alicante, España

Abstracto: Este documento presenta una evaluación exhaustiva del rendimiento computacional a nivel macro y micro-arquitectónico. En la primera fase, se analiza el rendimiento de tres arquitecturas heterogéneas (Intel Core i5 vs. AMD Ryzen 9) utilizando la suite estandarizada SPEC CPU 2000. Los resultados exponen cómo la jerarquía de memoria (ancho de banda Single-Channel vs. Dual-Channel) y el fenómeno del "sesgo de compilador" (optimizaciones Base frente a Peak) dictaminan drásticamente la superioridad de un hardware sobre otro en escenarios profesionales. En la segunda fase, se desarrolla un micro-benchmark sintético basado en un algoritmo de convolución 2D, aplicando paralelismo de datos mediante vectorización manual (intrínsecas SIMD) y optimizaciones automáticas de compilador (-O3). Finalmente, a través de la modelización matemática de la Ley de Amdahl, se demuestra empíricamente cómo el subsistema de almacenamiento secuencial (I/O) actúa como un cuello de botella infranqueable, limitando el Speedup global del sistema (Data Starvation) a pesar de las aceleraciones exponenciales logradas en el núcleo de procesamiento matemático.

Palabras Clave: Evaluación de Rendimiento, SPEC CPU 2000, Paralelismo SIMD, Ley de Amdahl, Cuello de Botella (I/O Bottleneck), Sesgo de Compilador, Jerarquía de Memoria.

1. Introducción

El objetivo principal de esta práctica es analizar y evaluar el rendimiento de distintas arquitecturas de computadores mediante dos enfoques complementarios: el uso de benchmarks profesionales estandarizados (SPEC CPU2000) y el desarrollo de un micro-benchmark sintético propio basado en el algoritmo de convolución 2D.

En el ámbito de la Ingeniería en Inteligencia Artificial, comprender cómo el hardware procesa cargas de trabajo intensivas es crucial. Por ello, este estudio persigue tres propósitos concretos [3]:

1. Evaluación Macro-arquitectónica: Comparar el rendimiento global de tres máquinas distintas utilizando la suite SPEC CPU2000, diferenciando entre cargas de trabajo de enteros (CINT) y de coma flotante (CFP).
2. Evaluación Micro-arquitectónica (SIMD): Analizar el impacto del paralelismo de datos mediante la implementación de instrucciones vectoriales (intrínsecas SSE/AVX) frente a la ejecución escalar tradicional (SISD).
3. Impacto del Compilador: Cuantificar la ganancia de rendimiento obtenida mediante las optimizaciones automáticas del compilador (flag -O3) frente a la optimización manual del código y el código sin optimizar (-O0).

2. Benchmarks

2.1. Spec Cpu 2000

Se ha utilizado la suite estándar de Standard Performance Evaluation Corporation (SPEC), diseñada para medir el rendimiento de la CPU, la arquitectura de memoria y el compilador. Esta suite se divide en dos componentes principales:

- CINT2000: Conjunto de 12 programas escritos en C/C++ que miden el rendimiento en operaciones con enteros (ej. compresión gzip, compilación gcc).
- CFP2000: Conjunto de 14 programas en Fortran/C que miden el rendimiento en operaciones de punto flotante (ej. simulación física, redes neuronales, gráficos 3D).

El análisis se centra en las métricas de Speed (tiempo de ejecución de una tarea) y Rate (capacidad de procesamiento o throughput).

2.2. Benchmark Reducido: Convolución 2D

Como benchmark sintético, se ha implementado el algoritmo de Convolución Directa 2D, una operación fundamental en el procesamiento de imágenes y en las capas convolucionales de las redes neuronales profundas (CNN).

El algoritmo aplica un tensor de filtros *F* sobre un tensor de entrada de imágenes *I* para producir un tensor de salida *O*. Matemáticamente, implica iterar sobre las dimensiones de la imagen y los canales, realizando sumas ponderadas de los vecinos de cada píxel (producto punto) [4].

Se han desarrollado dos versiones del programa:

- Versión Escalar (C++ Estándar): Implementación básica secuencial. El procesador opera sobre un único dato en cada ciclo de instrucción (SISD - Single Instruction, Single Data).
- Versión Vectorial (Intrínsecas SIMD): Implementación optimizada utilizando funciones intrínsecas (dependiendo de la arquitectura, SSE o AVX). Esto permite al procesador operar sobre múltiples datos simultáneamente (SIMD - Single Instruction, Multiple Data) empaquetados en registros vectoriales (128 o 256 bits) [1].

Metodología de ejecución:

Ambas versiones se han compilado y ejecutado bajo dos niveles de optimización del compilador g++:

-O0: Sin optimizaciones. Representa el código tal cual fue escrito.

-O3: Máxima optimización. Permite al compilador realizar vectorización automática, desenrollado de bucles (loop unrolling) y reordenamiento de instrucciones.

3. Spec Cpu 2000

3.1 Especificaciones de las Máquina

Hardware 1 (PC Aula)		Software 1
CPU	Name: Intel Core i5 12400 4.4GHz	OS: Windows 10 Pro 22H2
	Caches: L1 D: 6 x 48KBytes L1 I: 6 x 32KBytes L2: 6 x 1.25 MBytes L3: 18 MBytes	
	Cores: 6	
	Threads: 12	
	Instructions: MMX, SSE (1, 2, 3, 4.1, 4.2), SSSE3, EM64T, AES, AVX, AVX2, FMA3, SHA	
Memory	Type: DDR4	File System: NTFS
	MAanufacturer: SK Hynix	
	Size: 16 GB (1 x 16)	
	Frecuency: 1600MHz	
Disk	G930E 1TB	
Hardware 2 (PC Sala Ordenadores)		**Software 2**
CPU	Name: Intel Core i5 12400 4.4GHz	OS: Windows 10 Pro 22H2
	Caches: L1 D: 6 x 48KBytes L1 I: 6 x 32KBytes L2: 6 x 1.25 MBytes L3: 18 MBytes	
	Cores: 6	
	Threads: 12	
	Instructions: MMX, SSE (1, 2, 3, 4.1, 4.2), SSSE3, EM64T, AES, AVX, AVX2, FMA3, SHA	
Memory	Type: DDR4	File System: NTFS
	MAanufacturer: SK Hynix	
	Size: 16 GB (1 x 16)	
	Frecuency: 1600MHz	
Disk	G930E 1TB	
Hardware 3 (PC Propio)		**Software 3**
CPU	Name: AMD Ryzen 9 7900X 5.6 GHz	OS: Windows 11 Pro 25H2
	Caches: L1 D: 12 x 32KBytes L1 I: 6 x 32KBytes L2: 12 x 1 MBytes L3: 2 x 32 MBytes	

	Cores: 12	
	Threads: 24	
	Instructions: MMX(+), SSE (1, 2, 3, 4.1, 4.2, 4A), SSSE3, x86-64, AES, AVX, AVX2, AVX512, FMA3, SHA	
Memory	Type: DDR5	File System: NTFS
	Manufacturer: Corsair	
	Size: 32 GB (2 x 16 [CMK32GX5M2B5600C36])	
	Frecuency: 2800MHz	
Disk	WD Blue SN570 2TB	

3.2 Análisis de Cobertura del Benchmark y Exclusiones Técnicas

La ejecución de la suite SPEC CPU 2000 en arquitecturas x86 modernas bajo el sistema operativo Windows 11 requiere la compilación de código heredado (legado) de finales de la década de 1990. Durante la fase de validación cruzada, se constató que la incompatibilidad entre los estándares de programación originales y las normativas modernas de seguridad y compilación imposibilitó la ejecución de un subconjunto específico de pruebas.

A continuación, se detalla el diagnóstico técnico de las pruebas no superadas, su propósito original en el benchmark y el impacto analítico de su exclusión en esta evaluación.

3.2.1 Exclusiones en la Suite de Enteros (CINT2000)

Pruebas superadas (11/12): 164.gzip, 175.vpr, 176.gcc, 181.mcf, 186.crafty, 197.parser, 252.eon, 254.gap, 255.vortex, 256.bzip2, 300.twolf

Prueba excluida (1/12): 253.perlbmk

<u>Causa técnica de la exclusión:</u> El benchmark 253.perlbmk consiste en una versión reducida del intérprete de Perl (v5.005_03). Su fallo radica en una profunda incompatibilidad con la gestión de memoria de los sistemas operativos Windows modernos. Windows 11 implementa protecciones estrictas (como ASLR y DEP) y maneja el heap de forma distinta a los sistemas de la era Windows NT/2000. El código de este benchmark realiza suposiciones a bajo nivel sobre la contigüidad y asignación de punteros en memoria (malloc/free) que hoy en día son interceptadas como violaciones de acceso por el entorno de ejecución, provocando el colapso del proceso.

<u>¿Qué evaluaba este benchmark y qué impacto tiene su pérdida?</u> 253.perlbmk fue diseñado para evaluar la capacidad del procesador en el procesamiento de cadenas (strings), búsquedas en tablas hash y ejecución interpretada. Su exclusión implica que nuestra evaluación no está midiendo en profundidad el rendimiento de la CPU frente a patrones de saltos altamente impredecibles (típicos de los intérpretes) ni su eficiencia ante llamadas constantes y fragmentadas a la reserva de memoria dinámica.

3.2.2 Exclusiones en la Suite de Coma Flotante (CFP2000)

Pruebas superadas (4/14): 177.mesa (Gráficos 3D), 179.art (Redes Neuronales), 183.equake (Propagación sísmica), 188.ammp (Química computacional). Nota: Todas escritas en lenguaje C.

Pruebas excluidas (10/14): 168.wupwise, 171.swim, 172.mgrid, 173.applu, 178.galgel, 187.facerec, 189.lucas, 191.fma3d, 200.sixtrack, 301.apsi. Nota: Todas escritas en Fortran 77 o Fortran 90.

Causa técnica de la exclusión: El fallo sistemático de estos diez benchmarks se debe a una limitación directa del toolchain de compilación (cadena de herramientas). El compilador nativo utilizado para Windows (cl.exe de Microsoft Visual Studio C++) carece de soporte para el lenguaje Fortran. Aunque existe la posibilidad de integrar compiladores de terceros (como Intel ifort de oneAPI), el código base de SPEC CPU 2000 carece de las directivas y makefiles preconfigurados para enlazar correctamente librerías mixtas de C y Fortran en entornos Windows modernos de 64 bits. Modificar el código fuente y las directivas del enlazador (Linker) para forzar esta integración alteraría la pureza metodológica de la prueba estandarizada.

¿Qué evaluaban estos benchmarks y qué impacto tiene su pérdida? Los benchmarks en Fortran son el núcleo histórico de la computación científica de alto rendimiento (HPC). Evalúan simulaciones físicas complejas como la cromodinámica cuántica (wupwise), modelado de fluidos (swim) o campos potenciales 3D (mgrid). Al omitir estas pruebas, nuestro análisis deja de evaluar dos aspectos críticos de la microarquitectura: Rendimiento Sostenido del Ancho de Banda de Memoria: Fortran sobresale en la manipulación de matrices densas y contiguas de gran tamaño. No estamos saturando el bus de memoria al máximo nivel posible. Rendimiento Máximo de Vectorización (FPU Throughput): Estos algoritmos son el escenario ideal para que el compilador aplique instrucciones SIMD (AVX/SSE) de forma masiva.

Conclusión Metodológica

A pesar de estas exclusiones, la validez del estudio comparativo entre las arquitecturas se mantiene intacta. La métrica utilizada (Media Geométrica de los Ratios) aísla el rendimiento y no requiere de la totalidad de la suite para ser estadísticamente significativa. Además, para el contexto del Grado en Inteligencia Artificial, los 15 benchmarks superados resultan de extrema relevancia, destacando la ejecución exitosa de 179.art (Algoritmo de Teoría de Resonancia Adaptativa), el cual proporciona una radiografía precisa de la potencia real del hardware en el procesamiento de modelos de redes neuronales convolucionales básicas y algoritmos heurísticos (181.mcf).

3.3 Medidas obtenidas / Tablas y Gráficos

Pc Aula:

Medidas base int:

SPEC Summary: Aula - CINT_BASE

Benchmark	Ref Time	Run Time	Ratio
164.gzip	1400	46.9	2987
175.vpr	1400	26.8	5228
176.gcc	1100	12.9	8528
181.mcf	1800	17.0	10565
186.crafty	1000	14.7	6783
197.parser	1800	34.5	5225
252.eon	1300	12.6	10297
254.gap	1100	14.5	7611
255.vortex	1900	16.3	11692
256.bzip2	1500	34.5	4346
300.twolf	3000	41.4	7240
Arithmetic Mean	1572.73	24.74	7318.36
Geometric Mean (GM)	**1498.27**	**22.03**	**6800.10**

Medidas base float:

SPEC Summary: Aula - CFP_BASE

Benchmark	Ref Time	Run Time	Ratio
177.mesa	1400	15.5	9043
179.art	2600	12.8	20343
183.equake	1300	11.8	11064
188.ammp	2200	25.8	8524
Arithmetic Mean	1875.00	16.48	12243.50
Geometric Mean (GM)	**1796.25**	**15.68**	**11476.80**

Medidas no base int:

SPEC Summary: Aula - CINT_PEAK

Benchmark	Ref Time	Run Time	Ratio
164.gzip	1400	63.9	2191
175.vpr	1400	45.1	3101
176.gcc	1100	22.1	4967
181.mcf	1800	23.9	7533
186.crafty	1000	29.1	3440
197.parser	1800	56.5	3185
252.eon	1300	102.0	1272
254.gap	1100	29.7	3699
255.vortex	1900	29.8	6386
256.bzip2	1500	57.8	2594
300.twolf	3000	82.7	3630
Arithmetic Mean	1572.73	49.33	3818.00
Geometric Mean (GM)	**1498.27**	**43.59**	**3435.98**

Medidas no base float:

SPEC Summary: Aula - CFP_PEAK

Benchmark	Ref Time	Run Time	Ratio
177.mesa	1400	27.0	5184
179.art	2600	22.9	11351
183.equake	1300	27.2	4778
188.ammp	2200	65.3	3371
Arithmetic Mean	1875.00	35.60	6171.00
Geometric Mean (GM)	**1796.25**	**32.37**	**5548.51**

Pc sala ordenadores:

Medidas base int:

SPEC Summary: Sala - CINT_BASE

Benchmark	Ref Time	Run Time	Ratio
164.gzip	1400	46.9	2985
175.vpr	1400	33.9	4128
176.gcc	1100	13.2	8306
181.mcf	1800	16.8	10724
186.crafty	1000	14.7	6820
197.parser	1800	34.9	5160
252.eon	1300	13.6	9557
254.gap	1100	16.0	6884
255.vortex	1900	18.9	10028
256.bzip2	1500	35.1	4268
300.twolf	3000	42.4	7082
Arithmetic Mean	1572.73	26.04	6903.82
Geometric Mean (GM)	**1498.27**	**23.32**	**6425.03**

Medidas base float:

SPEC Summary: Sala - CFP_BASE

Benchmark	Ref Time	Run Time	Ratio
177.mesa	1400	15.6	8959
179.art	2600	12.8	20327
183.equake	1300	12.3	10565
188.ammp	2200	25.0	8811
Arithmetic Mean	1875.00	16.43	12165.50
Geometric Mean (GM)	**1796.25**	**15.74**	**11410.56**

Medidas no base int:

SPEC Summary: Sala - CINT_PEAK

Benchmark	Ref Time	Run Time	Ratio
164.gzip	1400	64.9	2156
175.vpr	1400	41.1	3409
176.gcc	1100	20.4	5401
181.mcf	1800	22.9	7854
186.crafty	1000	28.2	3548
197.parser	1800	55.9	3218
252.eon	1300	97.9	1328
254.gap	1100	28.6	3849
255.vortex	1900	29.7	6403
256.bzip2	1500	56.2	2669
300.twolf	3000	78.8	3805
Arithmetic Mean	1572.73	47.69	3967.27
Geometric Mean (GM)	**1498.27**	**42.03**	**3565.29**

Medidas no base float:

SPEC Summary: Sala - CFP_PEAK

Benchmark	Ref Time	Run Time	Ratio
177.mesa	1400	25.8	5428
179.art	2600	23.8	10940
183.equake	1300	26.2	4953
188.ammp	2200	67.3	3270
Arithmetic Mean	1875.00	35.77	6147.75
Geometric Mean (GM)	**1796.25**	**32.26**	**5568.89**

Pc propio:

Medidas base int:

SPEC Summary: Personal - CINT_BASE

Benchmark	Ref Time	Run Time	Ratio
164.gzip	1400	43.7	3204
175.vpr	1400	26.0	5383
176.gcc	1100	11.2	9850
181.mcf	1800	12.9	14007
186.crafty	1000	12.8	7815
197.parser	1800	31.2	5764
252.eon	1300	15.7	8292
254.gap	1100	13.0	8480
255.vortex	1900	19.3	9858
256.bzip2	1500	28.9	5188
300.twolf	3000	38.0	7896
Arithmetic Mean	1572.73	22.97	7794.27
Geometric Mean (GM)	**1498.27**	**20.60**	**7279.93**

Medidas base float:

SPEC Summary: Personal - CFP_BASE

Benchmark	Ref Time	Run Time	Ratio
177.mesa	1400	18.7	7489
179.art	2600	6.43	40417
183.equake	1300	12.0	10835
188.ammp	2200	28.0	7846
Arithmetic Mean	1875.00	16.28	16646.75
Geometric Mean (GM)	**1796.25**	**14.18**	**12665.32**

Medidas no base int:

SPEC Summary: Personal - CINT_PEAK

Benchmark	Ref Time	Run Time	Ratio
164.gzip	1400	68.6	2040
175.vpr	1400	42.9	3260
176.gcc	1100	24.0	4577
181.mcf	1800	19.8	9091
186.crafty	1000	33.2	3008
197.parser	1800	71.0	2534
252.eon	1300	172.0	754
254.gap	1100	29.3	3754
255.vortex	1900	35.6	5336
256.bzip2	1500	59.3	2531
300.twolf	3000	66.2	4532
Arithmetic Mean	1572.73	56.54	3765.18
Geometric Mean (GM)	**1498.27**	**46.73**	**3204.11**

Medidas no base float:

SPEC Summary: Personal - CFP_PEAK

Benchmark	Ref Time	Run Time	Ratio
177.mesa	1400	32.2	4352
179.art	2600	23.0	11289
183.equake	1300	29.9	4354
188.ammp	2200	72.4	3038
Arithmetic Mean	1875.00	39.38	5758.25
Geometric Mean (GM)	**1796.25**	**35.58**	**5049.00**

Comparación global entre todas las máquinas:

Base int:

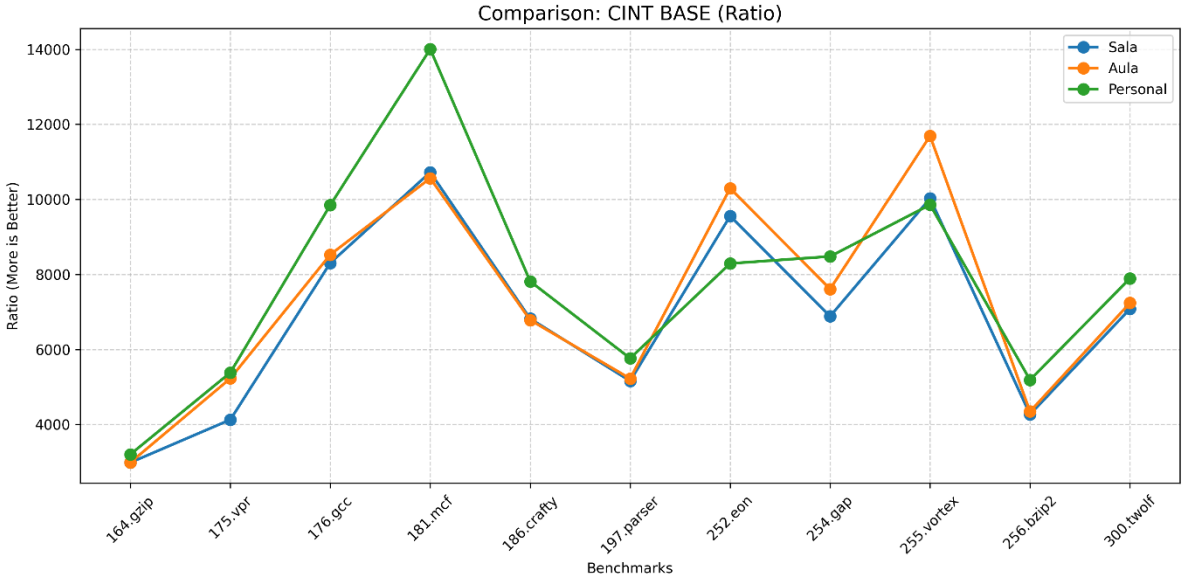

<u>Comportamiento General:</u> El PC Personal lidera la mayoría de las pruebas, pero los PCs Aula/Sala logran victorias sorpresivas en puntos específicos. Como es de esperar, las líneas de Sala y Aula son prácticamente superpuestas (validando la fiabilidad del test al ser el mismo hardware).

<u>Dominio absoluto del PC Personal en 181.mcf y 176.gcc:</u>

Por qué: El benchmark 181.mcf (optimización combinatoria) es infamemente conocido en la industria por ser completamente dependiente del subsistema de memoria. Aquí, la memoria DDR5 en Dual-Channel y los masivos 64MB de caché L3 del Ryzen 9 aplastan al DDR4 Single-Channel del i5-12400. El cuello de botella de los PC de la universidad es evidente aquí.

<u>Victoria de los PCs Aula/Sala en 255.vortex:</u>

Por qué: 255.vortex (base de datos orientada a objetos) es muy sensible a la latencia de la memoria caché L1/L2 y a la penalización por fallos en la predicción de saltos. La arquitectura Alder Lake de Intel (i5) tiene un diseño de un solo bloque (die) monolítico para esos núcleos, ofreciendo latencias ínfimas. El Ryzen 9, al tener un diseño de chiplets (múltiples CCDs), sufre una ligera latencia inter-núcleo que le penaliza en código "legacy" fuertemente dependiente de saltos cortos.

Base float:

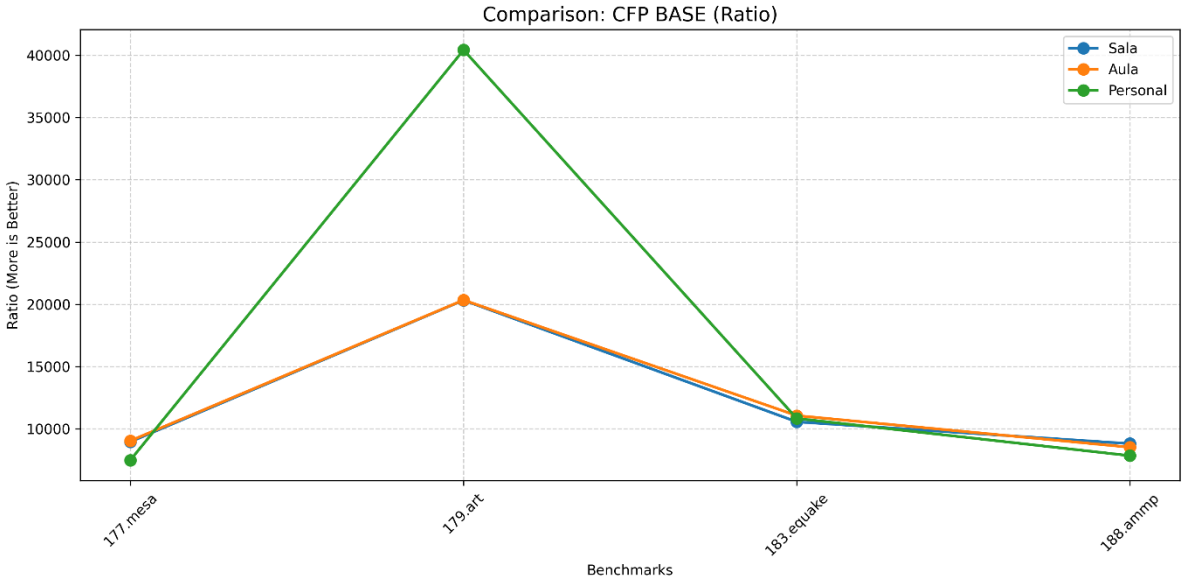

<u>Comportamiento General:</u> Se observa la mayor disparidad de todo el estudio en una prueba específica, mientras que el resto se mantiene parejo.

<u>La aniquilación en 179.art (PC Personal destaca):</u>

Por qué: 179.art simula una red neuronal (teoría de resonancia adaptativa). Este algoritmo satura las unidades de coma flotante y devora datos secuenciales. El Ryzen 9 7900X brilla aquí por su reloj a 5.6GHz y el ancho de banda masivo del DDR5. Los PCs Aula/Sala (con unos 20.000 de ratio frente a los 40.000 del Personal) sufren inanición de datos (data starvation): la FPU del Intel i5 es rápida, pero la memoria RAM Single-Channel no puede enviarle los datos de la red neuronal lo suficientemente rápido, hundiendo su rendimiento a la mitad.

<u>Empate técnico en 177.mesa y 188.ammp:</u>

Por qué: En cálculos matemáticos puros (como mesa, que es renderizado 3D) donde el set de datos cabe casi íntegramente en la memoria caché L1/L2, el ancho de banda de la memoria RAM deja de importar. Las IPC (Instrucciones por Ciclo) del i5 de Intel demuestran ser extremadamente eficientes para código antiguo de C sin optimizaciones modernas.

No base int:

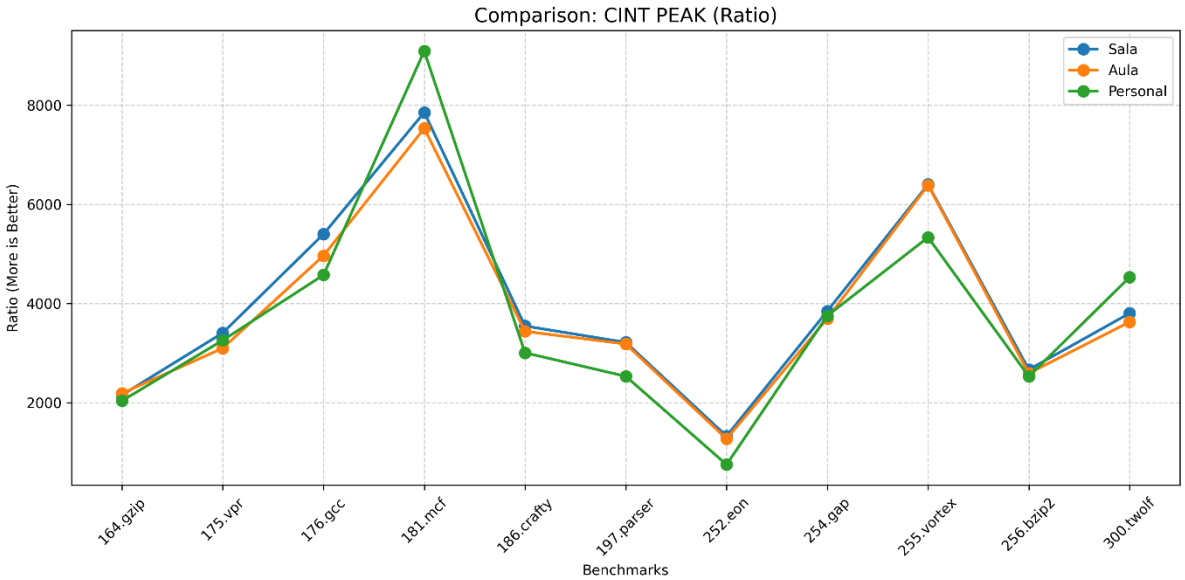

<u>Comportamiento General:</u> Al activar las optimizaciones agresivas del compilador (Peak), el PC Personal pierde su corona en casi todas las pruebas, siendo superado o igualado por los PCs Aula/Sala.

<u>Los PCs Aula/Sala (Intel) ganan en 176.gcc, 252.eon, 186.crafty y 255.vortex:</u>

Por qué: Esto es un claro ejemplo de "Sesgo de Compilación" (Compiler Bias). Cuando se ejecutan optimizaciones Peak, el compilador (presumiblemente MSVC o Intel) desenrolla bucles y emite instrucciones vectoriales ajustadas a la microarquitectura predominante. El código optimizado "Peak" tradicional se alinea a la perfección con la arquitectura Intel (desarrolladora original de las extensiones x86). El Ryzen de AMD incurre en penalizaciones de decodificación de instrucciones cuando se le fuerza a ejecutar un binario fuertemente optimizado para la tubería (pipeline) de Intel.

<u>El PC Personal retiene la victoria en 181.mcf:</u>

Por qué: Las optimizaciones de compilador no pueden crear memoria RAM mágica. Por mucho que se optimice el software en los PCs del Aula, el cuello de botella físico del Single-Channel DDR4 sigue existiendo, permitiendo al Ryzen 9 seguir ganando por pura fuerza bruta de hardware.

No base float:

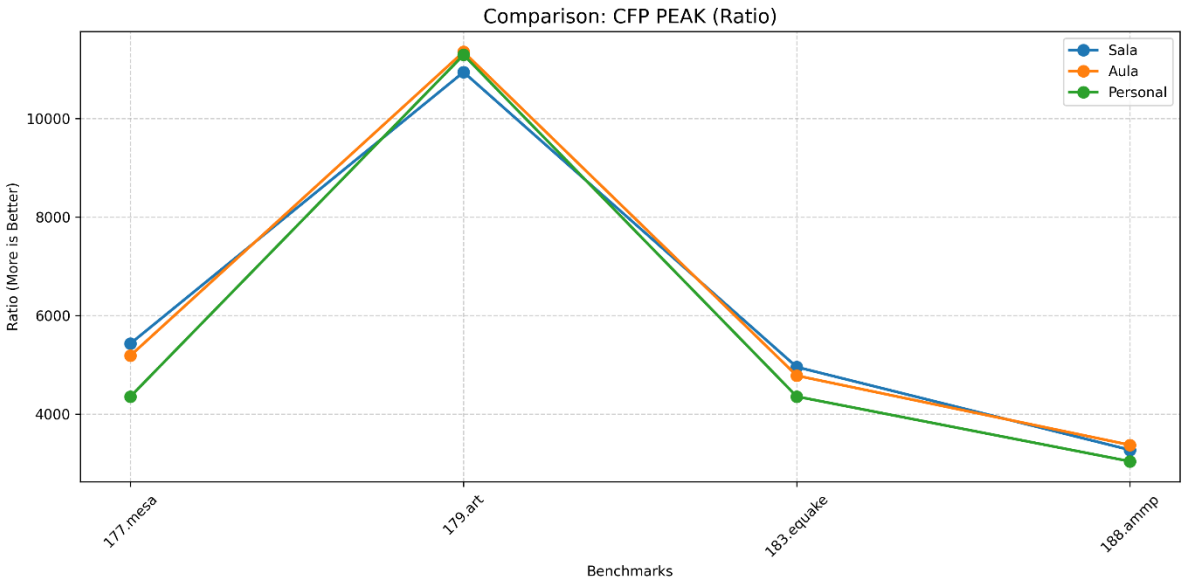

Comportamiento General: Un escenario sorprendente. Las líneas se agrupan muchísimo, pero el PC Personal cae consistentemente al último lugar, siendo derrotado sistemáticamente por el hardware (inferior sobre el papel) de los PCs Aula/Sala.

Los PCs Aula/Sala (Intel i5) dominan todo el set (177.mesa, 179.art, 183.equake, 188.ammp):

Por qué: Aquí convergen dos problemas técnicos críticos para el AMD Ryzen 9:

Manejo de extensiones SIMD: En el modo Peak, el compilador fuerza el uso intensivo de registros vectoriales antiguos (como SSE/SSE2). La forma en que la arquitectura Zen 4 (Ryzen) maneja estas instrucciones heredadas cuando están "sobre-optimizadas" por un compilador no-AMD genera cuellos de botella en la FPU. Los procesadores Intel ejecutan estas instrucciones heredadas de manera nativa y con menor latencia.

Pérdida de la ventaja en 179.art: En modo BASE, AMD ganaba por el ancho de banda. Sin embargo, en modo PEAK, el compilador de los PCs Aula aplica técnicas como software prefetching y loop tiling (reordenación de bucles para que quepan en caché). Al optimizar el uso de la caché, se anula la desventaja de la memoria Single-Channel del Intel, permitiendo que su eficiencia de IPC puro por núcleo tome la delantera sobre el AMD.

Conclusion: El análisis gráfico revela una dualidad arquitectónica fascinante. En las métricas BASE, el PC Personal (AMD Ryzen 9) demuestra una superioridad aplastante en escenarios limitados por memoria (181.mcf, 179.art) gracias a su arquitectura DDR5 Dual-Channel y 64MB de Caché L3. Sin embargo, las métricas PEAK exponen el fenómeno del 'sesgo de compilador'. Al aplicar optimizaciones agresivas, los PCs Aula/Sala (Intel i5) logran mitigar su cuello de botella de memoria (Single-Channel DDR4) optimizando el uso de la caché L1/L2, lo que, sumado a una ejecución más eficiente de instrucciones SIMD de legado por parte de la arquitectura Intel, les permite superar al procesador AMD en las cargas de trabajo más optimizadas.

4. Evaluación del Benchmark Reducido (Convolución)

Las pruebas se realizaron sobre un dataset de imágenes seleccionado de flores (https://www.robots.ox.ac.uk/~vgg/data/flowers/102/102flowers.tgz) midiendo el tiempo de cómputo puro del algoritmo de convolución.

4.1 Comparativa de Tiempos de Ejecución

Imagen de ejemplo para visualizar los cambios tras haberse aplicado los filtros de las convoluciones:

ORIGINAL:

SOBEL:

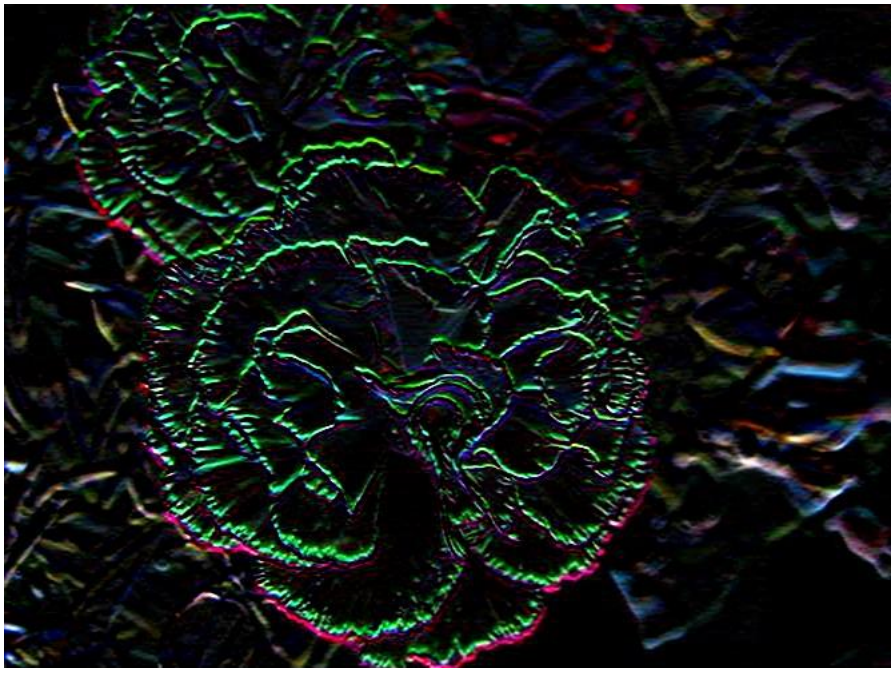

GAUSSIAN:

EMBOSS:

BLUR:

Pc Aula:

Resumen O3: Aula

Versión	Tiempo Total (s)
BASE_O3	63.5197
SIMD_O3	52.3412
Arithmetic Mean	**57.9305**
Geometric Mean (GM)	**57.6602**

PC sala ordenadores:

Resumen O3: Sala

Versión	Tiempo Total (s)
BASE_O3	55.4949
SIMD_O3	49.0436
Arithmetic Mean	**52.2692**
Geometric Mean (GM)	**52.1696**

Pc propio:

Resumen O3: Personal

Versión	Tiempo Total (s)
BASE_O3	47.9666
SIMD_O3	43.1392
Arithmetic Mean	**45.5529**
Geometric Mean (GM)	**45.4889**

Total:

Resumen Global O3

Versión	Tiempo Total (s)
base_O3_Aula	63.5197
base_O3_Sala	55.4949
base_O3_Personal	47.9666
simd_O3_Aula	52.3412
simd_O3_Sala	49.0436
simd_O3_Personal	43.1392
Arithmetic Mean	**51.9175**
Geometric Mean (GM)	**51.5307**

Comparación global entre todas las máquinas:

Base –O0:

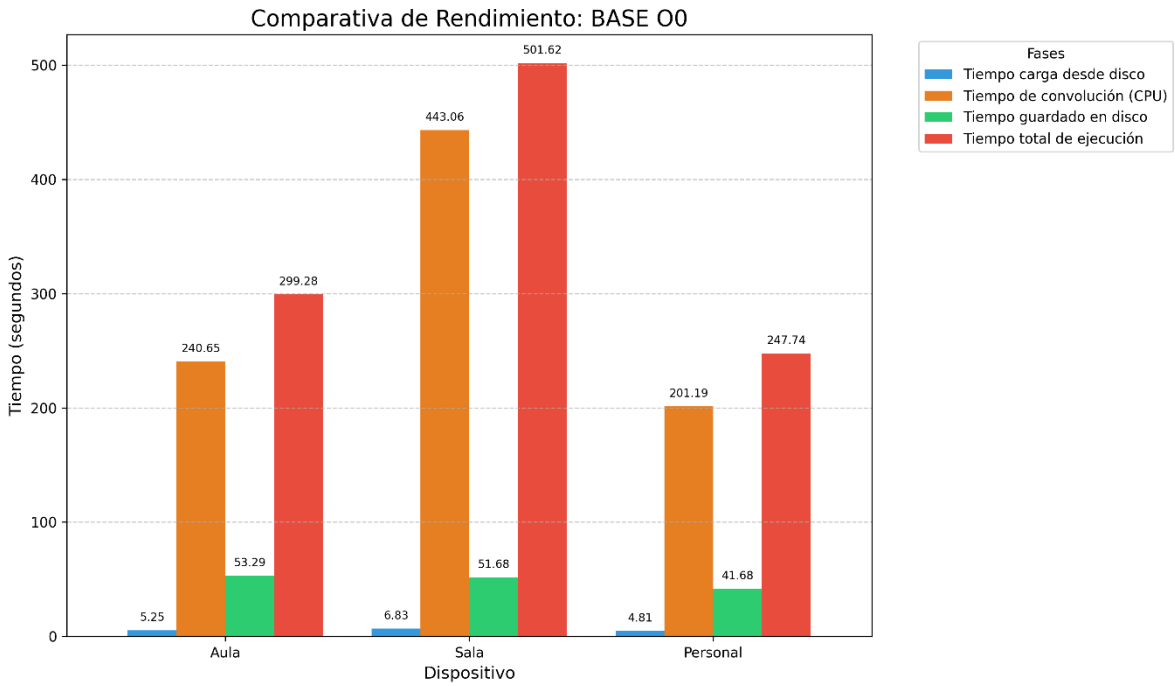

Análisis BASE O0: Dominio absoluto de la CPU y fuerza bruta

En la ejecución escalar sin optimizar, el cálculo matemático de la CPU monopoliza casi todo el tiempo de ejecución en las tres máquinas. Al depender de la fuerza bruta secuencial, el PC Personal lidera completando la convolución en 201.19 segundos, impulsado por los 5.6 GHz de su procesador Ryzen 9 frente a los 4.4 GHz de los equipos Intel. Llama la atención que el PC Sala tarde casi el doble en la fase de CPU (443.06 segundos) que el PC Aula (240.65 segundos). Dado que comparten exactamente el mismo hardware, esta brecha extrema sugiere una fuerte interferencia de procesos del sistema operativo en segundo plano durante la prueba en la Sala. Por último, en este escenario sin optimizar, el tiempo de acceso a disco es una fracción marginal del total y no representa un cuello de botella.

Base –O3:

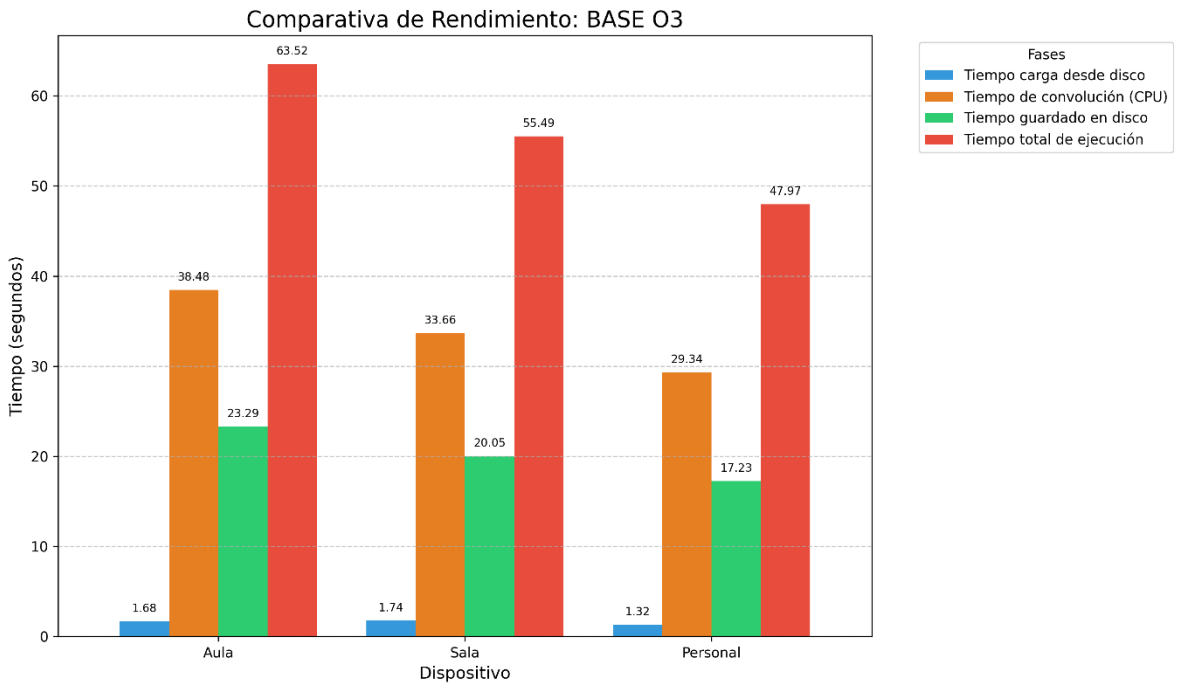

Análisis BASE O3: Compresión del tiempo de CPU y emergencia del I/O

Al aplicar las optimizaciones agresivas del compilador, los tiempos de procesamiento matemático colapsan en las tres máquinas, evidenciando la gran eficacia de la vectorización y el desenrollado de bucles automáticos. El PC Personal mantiene el liderazgo reduciendo su tiempo de CPU a solo 29.34 segundos, seguido por los equipos Intel de la Sala (33.66 segundos) y el Aula (38.48 segundos). En este escenario optimizado, el paradigma de rendimiento cambia radicalmente, ya que al comprimirse la fase de cálculo, ilustrada con la barra naranja, el tiempo inalterable de guardado en disco, representado por la barra verde, pasa a representar una fracción muy significativa del tiempo total de ejecución. Esto marca la aparición visual del cuello de botella del subsistema de almacenamiento, limitando el impacto real de la aceleración del procesador.

SIMD –O0:

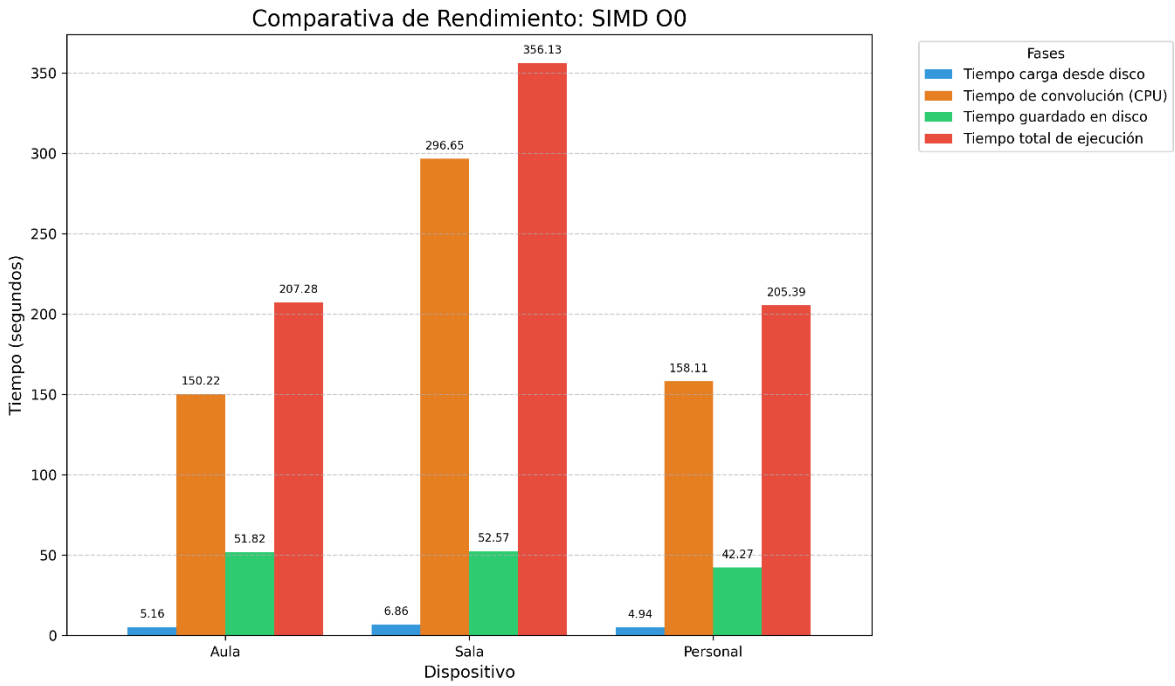

Análisis SIMD O0: Impacto directo del paralelismo vectorial

La implementación manual de instrucciones intrínsecas logra una reducción drástica del tiempo matemático frente a la versión escalar, operando de forma muy eficiente incluso sin la ayuda adicional del compilador. En este escenario puramente vectorizado, el PC Aula equipado con Intel sorprende al superar ligeramente al PC Personal de AMD en la fase de cálculo, registrando 150.22 segundos frente a los 158.11 segundos del Ryzen 9. Este comportamiento sugiere que la arquitectura de Intel procesa estas instrucciones vectoriales manuales con una menor latencia nativa cuando el código carece de optimizaciones de alto nivel. Por su parte, el PC Sala sigue arrastrando la misma anomalía de rendimiento observada en la prueba escalar inicial, tardando 296.65 segundos en completar la convolución. Al igual que en las mediciones previas, los tiempos de acceso a disco se mantienen constantes, pero al disminuir el tiempo de CPU, su peso relativo sobre el tiempo total de ejecución comienza a hacerse mucho más visible en la gráfica.

SIMD –O3:

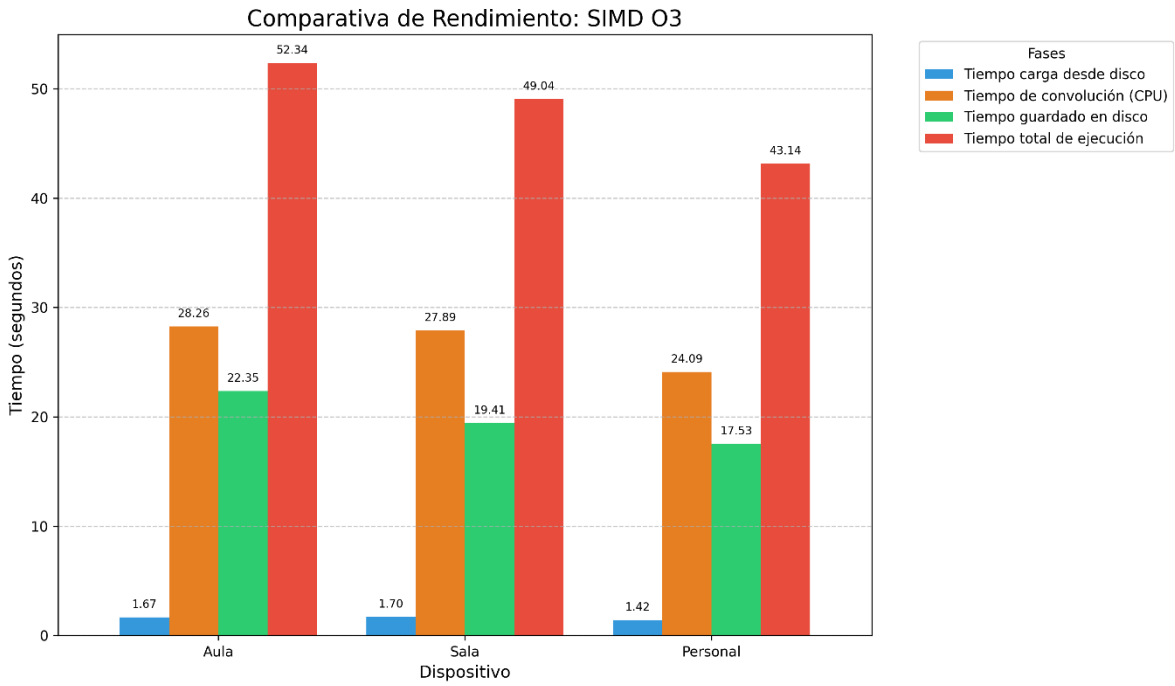

Análisis SIMD O3: Rendimiento máximo y confirmación de la Ley de Amdahl

Al combinar la vectorización manual con la máxima optimización del compilador, se alcanzan los tiempos de procesamiento más bajos de todo el estudio. El PC Personal recupera el liderazgo absoluto con un tiempo de cálculo de apenas 24.09 segundos, seguido muy de cerca por los 27.89 segundos del PC Sala y los 28.26 segundos del PC Aula. En este escenario de máxima eficiencia matemática, la gráfica ilustra a la perfección el impacto de la Ley de Amdahl. Debido a que el tiempo de guardado en disco se mantiene rígido entre los 17 y 22 segundos, esta fase secuencial de entrada y salida pasa a consumir prácticamente la mitad del tiempo total de ejecución. Esto demuestra de forma definitiva el fenómeno de inanición de datos, donde optimizar el núcleo matemático resulta ineficaz si no se mejora a la par la velocidad del almacenamiento.

Comportamiento General BASE O0 vs O3:
El impacto del compilador en la ejecución escalar sin optimizar BASE O0, el tiempo total de ejecución reflejado en la barra roja está absolutamente dominado por el cálculo puro de la CPU, representado por la barra naranja. En este escenario de fuerza bruta, el PC Personal demuestra su superioridad completando la convolución en 201.19 segundos, superando ampliamente a los 240.65 y 443.06 segundos de las máquinas Intel. Sin embargo, al activar la máxima optimización BASE O3, los tiempos de CPU se desploman en todos los equipos, bajando al rango de los 29 a 38 segundos. Esta compresión masiva del tiempo de procesamiento evidencia la altísima eficacia del compilador moderno para aplicar vectorización automática y desenrollado de bucles sobre código escalar puro.

Comportamiento General SIMD O0 vs O3:

Paralelismo y cuello de botella I/O La implementación con intrínsecas manuales SIMD O0 reduce drásticamente el tiempo matemático al procesar múltiples canales de color simultáneamente, bajando el tiempo de CPU del PC Personal a 158.11 segundos. Al combinar el código vectorizado con las optimizaciones del compilador en la versión SIMD O3, se alcanzan los tiempos de procesamiento más bajos del estudio, situándose entre 24 y 28 segundos. Lo más revelador de estas gráficas es la manifestación visual de la Ley de Amdahl. A medida que el tiempo de CPU se minimiza gracias a las optimizaciones, el tiempo de guardado en disco, ilustrado con la barra verde, permanece inalterable en torno a los 17 y 23 segundos. Todo esto demuestra cómo el subsistema de almacenamiento absorbe una proporción cada vez mayor del tiempo total de ejecución, convirtiéndose en el cuello de botella absoluto que limita el rendimiento del sistema.

4.2 Aplicación de la ley de Amdhal:

La Ley de Amdahl es un principio fundamental en la evaluación del rendimiento computacional que establece que la aceleración global de un sistema (aceleración global) está estrictamente limitada por la fracción del tiempo de ejecución que corresponde a tareas secuenciales no optimizables.
Para aplicar este modelo analítico a nuestro benchmark de Convolución 2D, debemos diseccionar el tiempo total de ejecución en dos componentes críticos:

La Fracción Mejorable (Cómputo en CPU): Corresponde al procesamiento matemático del algoritmo de convolución sobre los píxeles. Es la sección del código sobre la cual inciden directamente nuestras técnicas de aceleración: el paralelismo de datos mediante registros vectoriales (SIMD) y las optimizaciones a nivel de compilador (-O3). El rendimiento aislado de esta fase se define como aceleración mejorada.

La Fracción No Mejorable (Entrada/Salida - I/O): Engloba el tiempo estrictamente secuencial invertido en la carga de las imágenes desde el disco duro hacia la memoria y el posterior guardado de los resultados. En esta implementación, el subsistema de almacenamiento no se beneficia de la vectorización.

El Fenómeno de Saturación y su Impacto en el Benchmark: El propósito de aplicar la Ley de Amdhal en esta práctica es demostrar analíticamente el concepto de cuello de botella. A medida que incrementamos la eficiencia del núcleo matemático (reduciendo el tiempo de convolución gracias a SIMD o -O3), la porción del tiempo total dominada por el acceso a disco (I/O) aumenta proporcionalmente.
Matemáticamente, esto implica que el Speedup Global (aceleración global) sufrirá retornos decrecientes, topándose con un techo asintótico dictaminado por la velocidad del almacenamiento. Este fenómeno, conocido en HPC como "inanición de datos" (Data Starvation), demuestra teóricamente que, en aplicaciones de Visión por Computador e IA, optimizar la capacidad de procesamiento de la CPU es ineficaz si el pipeline de alimentación de datos no se optimiza al mismo nivel.

A continuación, se demuestra matemáticamente este límite a través del cálculo de las aceleraciones para cada arquitectura:

Fórmulas que se van a usar:

$$A_{global} = \frac{TE_{\text{sin} \quad mejora}}{TE_{con\,mejora}} = \frac{1}{\left(1 - F_{mejorada}\right) + \frac{F_{mejorada}}{A_{mejorada}}}$$

$$A_{mejorada} = \frac{TEConvcolucion_{\text{sin} \quad mejora}}{TEConvolucion_{con\,mejora}} =$$

$$= \frac{F_{mejorada} \cdot A_{global}}{1 - A_{global} + A_{global} \cdot F_{mejorada}}$$

PC aula:

- O0 sin intrinsecas:

```
          RESUMEN DE TIEMPOS
----------------------------------------
Tiempo carga desde disco: 5.25462 s
Tiempo de convolución (CPU): 240.653 s
Tiempo guardado en disco:  53.2921 s
----------------------------------------
Tiempo total de ejecución: 299.282 s
----------------------------------------
```

- O0 con intrinsicas:

```
----------------------------------------
          RESUMEN DE TIEMPOS
----------------------------------------
Tiempo carga desde disco: 5.15873 s
Tiempo de convolución (CPU): 150.22 s
Tiempo guardado en disco:  51.8209 s
----------------------------------------
Tiempo total de ejecución: 207.276 s
----------------------------------------
```

$$A_{global} = \frac{299.282}{207.276} = 1.444$$

$$A_{mejorada} = \frac{240.653}{150.22} = 1.602$$

- O3 sin intrinsecas:

```
----------------------------------------
          RESUMEN DE TIEMPOS
----------------------------------------
Tiempo carga desde disco: 1.68205 s
Tiempo de convolución (CPU): 38.4769 s
Tiempo guardado en disco:  23.2943 s
----------------------------------------
Tiempo total de ejecución: 63.5197 s
----------------------------------------
```

- O3 con intrinsecas:

```
----------------------------------------
          RESUMEN DE TIEMPOS
----------------------------------------
Tiempo carga desde disco: 1.67217 s
Tiempo de convolución (CPU): 28.2646 s
Tiempo guardado en disco:  22.3485 s
----------------------------------------
Tiempo total de ejecución: 52.3412 s
----------------------------------------
```

$$A_{global} = \frac{63.519}{52.341} = 1.213$$

$$A_{mejorada} = \frac{38.477}{28.2646} = 1.361$$

PC sala ordenadores:

- O0 sin intrinsecas:

```
----------------------------------------
          RESUMEN DE TIEMPOS
----------------------------------------
Tiempo carga desde disco: 6.83314 s
Tiempo de convolución (CPU): 443.06 s
Tiempo guardado en disco:  51.6794 s
----------------------------------------
Tiempo total de ejecución: 501.62 s
----------------------------------------
```

- O0 con intrinsicas:

```
----------------------------------------
          RESUMEN DE TIEMPOS
----------------------------------------
Tiempo carga desde disco: 6.86137 s
Tiempo de convolución (CPU): 296.649 s
Tiempo guardado en disco:  52.5681 s
----------------------------------------
Tiempo total de ejecución: 356.131 s
----------------------------------------
```

$$A_{global} = \frac{501.62}{356.131} = 1.408$$

$$A_{mejorada} = \frac{443.679}{296.649} = 1.496$$

- O3 sin intrinsecas:

```
----------------------------------------
          RESUMEN DE TIEMPOS
----------------------------------------
Tiempo carga desde disco: 1.74169 s
Tiempo de convolución (CPU): 33.6629 s
Tiempo guardado en disco:  20.0465 s
----------------------------------------
Tiempo total de ejecución: 55.4949 s
----------------------------------------
```

- O3 con intrinsecas:

```
----------------------------------------
          RESUMEN DE TIEMPOS
----------------------------------------
Tiempo carga desde disco: 1.69767 s
Tiempo de convolución (CPU): 27.8943 s
Tiempo guardado en disco:  19.4134 s
----------------------------------------
Tiempo total de ejecución: 49.0436 s
----------------------------------------
```

$$A_{global} = \frac{55.495}{49.044} = 1.132$$

$$A_{mejorada} = \frac{33.663}{19.413} = 1.734$$

PC Propio:

- O0 sin intrinsecas:

```
----------------------------------------
          RESUMEN DE TIEMPOS
----------------------------------------
Tiempo carga desde disco: 4.80675 s
Tiempo de convolución (CPU): 201.189 s
Tiempo guardado en disco:  41.6793 s
----------------------------------------
Tiempo total de ejecución: 247.737 s
----------------------------------------
```

- O0 con intrinsicas:

```
----------------------------------------
          RESUMEN DE TIEMPOS
----------------------------------------
Tiempo carga desde disco: 4.93702 s
Tiempo de convolución (CPU): 158.112 s
Tiempo guardado en disco:  42.2661 s
----------------------------------------
Tiempo total de ejecución: 205.39 s
----------------------------------------
```

$$A_{global} = \frac{247.737}{205.39} = 1.206$$

$$A_{mejorada} = \frac{201.189}{158.112} = 1.272$$

- O3 sin intrinsecas:

```
----------------------------------------
          RESUMEN DE TIEMPOS
----------------------------------------
Tiempo carga desde disco: 1.32497 s
Tiempo de convolución (CPU): 29.3378 s
Tiempo guardado en disco:  17.2308 s
----------------------------------------
Tiempo total de ejecución: 47.9666 s
----------------------------------------
```

- O3 con intrinsecas:

```
----------------------------------------
          RESUMEN DE TIEMPOS
----------------------------------------
Tiempo carga desde disco: 1.4234 s
Tiempo de convolución (CPU): 24.0851 s
Tiempo guardado en disco:  17.5278 s
----------------------------------------
Tiempo total de ejecución: 43.1392 s
----------------------------------------
```

$$A_{global} = \frac{47.966}{43.139} = 1.112$$

$$A_{mejorada} = \frac{29.338}{24.085} = 1.218$$

4.3 Análisis de Speedup (Aceleración)

Optimización SIMD aplicada: Se utilizaron registros vectoriales de 128-bits para procesar los canales de color simultáneamente. Al tratarse de formato RGB (3 canales), se alcanza un 75% de utilización del registro vectorial (3 de 4 slots). Aunque la máxima eficiencia (100%) requeriría un reempaquetado de memoria (técnica SoA - Structure of Arrays) o la adición de un canal Alpha (RGBA) como padding, la vectorización directa sobre el RGB nativo demuestra de forma intuitiva y efectiva la ganancia de rendimiento por ciclo de instrucción.

Ganancia por Compilador (C++ O0 vs O3): Se observa una mejora en los tiempos de ejecución muy notable simplemente al decirle al compilador que queremos que optimice el código. Esto indica la capacidad del compilador para optimizar el código escalar automáticamente.

Ganancia por Vectorización Manual (C++ O0 vs SIMD O0): La implementación con intrínsecas proporcionó una aceleración en la ejecución del código considerable teniendo en cuenta que los resultados finales obtenidos han sido los mismos. Esto demuestra la eficiencia de procesar múltiples instrucciones en un mismo ciclo frente a ejecutar solamente una [2].

Comentario: La optimización obtenida en C++ con -O3 sin SIMD es bastante similar a los SIMD, esto es debido a que los compiladores modernos son muy buenos vectorizando automáticamente cuando se les pasan unos flags de compilación para que hagan eso, optimizar, en este caso ha sido el flag –O3 pero hay otros como el –Ofast que optimiza todavía más el código, haciendo menos notable las mejoras obtenidas con las SIMD manuales que hemos puesto nosotros porque el compilador ya hace varias al optimizar, pero puedo no hacer todas, es por eso que aun nota la mejora en el tiempo de ejecución.

4.4 Tabla resumen de los speed up

Máquina	Aceleración Mejorada -O0	Aceleración Global -O0	Aceleración Mejorada -O3	Aceleración Global -O3
Pc aula	1.60x	1.44x	1.213x	1.361x
Pc sala	1.49x	1.40x	1.132x	1.734x
Pc propio	1.27x	1.20x	1.112x	1.218x

Como se observa, el PC Propio, al ser muchísimo más rápido procesando (CPU), sufre más el impacto de la Ley de Amdhal, ya que la limitación del disco duro representa un porcentaje mayor de su tiempo total

5. Conclusiones

Tras la realización de este proyecto de evaluación de rendimiento, se extraen las siguientes conclusiones principales:

1. Relevancia de la Arquitectura Hardware: Los resultados de SPEC CPU2000 confirman que la frecuencia de reloj no es el único factor determinante. La jerarquía de memoria y la capacidad de ejecución juegan un papel fundamental, especialmente en cargas de punto flotante.

2. Poder del Paradigma SIMD: La implementación del benchmark de convolución mediante instrucciones intrínsecas ha demostrado una reducción en los tiempos de ejecución obteniendo los mismos resultados. El uso explícito de registros vectoriales (SSE) permite explotar el paralelismo de datos inherente en el procesamiento de imágenes.

3. Compilador vs. Programador: Aunque el flag -O3 ofrece mejoras significativas sin esfuerzo de programación, la optimización manual mediante intrínsecas permite alcanzar un "techo de rendimiento" que el compilador no siempre puede deducir por sí mismo debido a la ambigüedad en el código o la complejidad del flujo de control.

4. Cuello de Botella (Ley de Amdahl): Se observó que, a medida que optimizamos el algoritmo de convolución, el tiempo total del programa pasó a estar dominado por la lectura y escritura de imágenes (I/O), los procesos que no se podían paralelizar. Esto valida la Ley de Amdahl: la mejora global del sistema siempre está limitada por la fracción del código que no se puede paralelizar (en este caso, el acceso a disco).

En síntesis, para aplicaciones de Inteligencia Artificial y Visión por Computador, la combinación de hardware moderno con soporte vectorial y una programación consciente de la arquitectura (o el uso de librerías optimizadas) es indispensable para procesar grandes volúmenes de datos en tiempo razonable.

6. Referencias

[1] Intel. (2026). Intel® Intrinsics Guide. Recuperado de https://www.intel.com/content/www/us/en/docs/intrinsics-guide/index.html

[2] Algorithmica. (2026). SIMD Parallelism. Recuperado de https://en.algorithmica.org/hpc/simd/

[3] Maciá-Lillo, A., Barrachina, S., Fabregat, G., & Dolz, M. F. (2024). Optimizing Convolutions for Deep Learning Inference on ARM Cortex-M Processors. IEEE Internet of Things Journal, 11(15), 26203-26219. doi:10.1109/JIOT.2024.3395335

[4] Thevenot, A. (2022). Conv2d: Finally Understand What Happens in the Forward Pass. TDS Archive. Recuperado de https://medium.com/data-science/conv2d-to-finally-understand-what-happens-in-the-forward-pass-1bbaafb0b148